

Relatório: Classificação Genômica

Redigido por: Caio Gaspar Paula , João Pedro Lima Afonso e Marcelo Trevine .

Criado em: 28 de jul. de 2026

Última atualização: 12 de ago. de 2026

1. Introdução

1.1. Contextualização e Motivação

O estudo do comportamento genético por meio do sequenciamento de RNA(RNA-Seq) desempenha um papel fundamental na identificação de padrões celulares e no diagnóstico oncológico. Utilizando como base de estudo dados reais do *The Cancer Genome Atlas* (TCGA) o projeto simula um desafio prático de aplicação de Ciência de Dados no contexto de saúde e biologia computacional preditiva.

No cenário proposto a classificação manual de amostras genéticas para cinco tipos de tumores distintos (Mama, Pulmão, Cólon, Rim e Próstata) representa um gargalo que consome tempo e recursos operacionais. Diante dessa dor, surge a necessidade de automatizar o processo de triagem e diagnóstico por meio de inteligência artificial de dados, transformando a complexidade dos dados de expressão gênica em uma ferramenta preditiva ágil, precisa e escalável.

1.2. Objetivo e Estrutura do Trabalho

Elaborado no contexto do Processo Trainee do Núcleo de Dados da Síntese Jr. este trabalho tem como objetivo principal desenvolver, avaliar e consolidar um modelo de Machine Learning capaz de prever o tipo de tumor de um paciente com base em sua assinatura genética.

Para estruturar o desenvolvimento da solução tecnológica e garantir as boas práticas de versionamento, o projeto foi dividido em três frentes principais e organizadas no repositório do projeto em notebooks específicos:

1. Limpeza e Pré-processamento dos Dados: Tratamento de valores nulos, duplicados, remoção de outliers e adequação das variáveis.
2. Análise Exploratória de Dados (EDA): Investigação do comportamento das variáveis, distribuição das classes e correlações genéticas relevantes.
3. Modelagem Preditiva e Avaliação: Treinamento de algoritmos de classificação, ajuste de parâmetros e validação do desempenho por meio de métricas como Acurácia, F1-Score e Matriz de Confusão.

2. Metodologia

2.1. Ambiente de Desenvolvimento e Tecnologias

Para realização do projeto foi utilizado a linguagem de programação Python (v3.14) executado em ambiente Jupyter Notebook, as principais bibliotecas utilizadas foram:



- Pandas: Utilizada para leitura de arquivos CSV, concatenação de datasets, checagem de integridade, filtrações por variância e exportação final.
- Numpy: Para operações vetoriais e matriciais, além de suporte numérico no tratamento de dados.
- Pathlib: Para gerenciamento seguro e multiplataforma de caminhos de arquivos do sistema.
- Matplotlib e Seaborn: Para geração de gráficos estatísticos, distribuição e visualização da frequência de expressão gênica por tumor.
- Scikit-learn: foi utilizada para dividir o dataset em treino e teste, realizar a normalização dos dados com RobustScaler e transformar variáveis categóricas em numéricas com LabelEncoder. O Random Forest foi utilizado para identificar as 50 principais features e, posteriormente, treinar o modelo final, capaz de prever o tipo de tumor com base na assinatura genômica de cada amostra.

O uso de ferramentas como Git e Github também foram essenciais para garantir o controle de versão por branches/PRs e uso da metodologia Scrum para a gestão ágil do projeto.

2.2. Estrutura dos Dados Brutos

Os dados brutos são compostos por dois arquivos no formato CSV: `data.csv` e `labels.csv`. O arquivo `data.csv` contém, em sua primeira coluna, as amostras (identificadas como *samples*). As demais colunas correspondem aos genes analisados, e cada célula armazena um valor numérico que



representa o nível de expressão gênica do respectivo gene em cada amostra celular.

O arquivo `labels.csv`, por sua vez, também apresenta, em sua primeira coluna, as mesmas amostras contidas em `data.csv`, preservando a correspondência entre os registros. A segunda coluna contém a classificação de cada amostra, indicando o tipo de tumor ao qual ela pertence.

A etapa de manipulação dos dados brutos consistiu na importação dos arquivos CSV para estruturas do tipo `DataFrame` da biblioteca `Pandas`, permitindo uma manipulação mais eficiente das informações. Em seguida, os arquivos `data.csv` e `labels.csv` foram concatenados com base na coluna de identificação das amostras (*Samples*), resultando em um único conjunto de dados denominado `df_final`. Esse `DataFrame` passou a ser composto pelas colunas `Samples`, que identificam cada amostra, pelas colunas correspondentes aos genes, que armazenam seus respectivos níveis de expressão gênica, e pela coluna `Class`, responsável por indicar o tipo de tumor associado a cada amostra.

2.3. Pipeline de Limpeza e Filtro de Variância

Inicialmente, utilizando o `df_final`, foi realizada a verificação da existência de valores nulos e de linhas duplicadas na base de dados, não sendo identificada a ocorrência de nenhum desses problemas. Dessa forma, a única etapa de pré-processamento consistiu na remoção das colunas cuja variância fosse inferior a 10%, uma vez que apresentam baixa variabilidade entre as amostras, visto que usar distâncias interquartis ou outros métodos tradicionais poderiam acabar por impactar o dataset e sua natureza biológica, e, conseqüentemente, reduzido potencial discriminativo para a identificação de alterações associadas à formação de células tumorais.



3. Análise Exploratória de Dados

3.1. Análise Univariada

Para a análise univariada, os dados do *dataframe_final* foram divididos em cinco outros *dataframes*, um para cada tipo de tumor, sendo estes: *df_prad* (próstata), *df_luad* (pulmão), *df_brca* (mama), *df_coad* (cólon) e *df_kirc* (rim). Posteriormente, houve a análise e a manipulação individual de tais *dataframes*, formando uma lista comparativa com os dez genes mais expressivos e menos expressivos de cada um. Ao final, foi definida a proporção de cada tipo de tumor em relação à amostra.

Como principais *insights* extraídos, temos:

- **Comparativo dos genes mais expressivo**



	LUAD/Pulmao	PRAD/Prostata	BRCA/Mama	COAD/Colon	KIRC/Rim
gene_230	126.0	73.0	243.0	75.0	99.0
gene_289	85.0	NaN	NaN	NaN	NaN
gene_6698	81.0	NaN	NaN	NaN	48.0
gene_15898	81.0	NaN	NaN	NaN	NaN
gene_5380	66.0	128.0	206.0	70.0	125.0
gene_3371	63.0	NaN	NaN	NaN	94.0
gene_232	59.0	51.0	200.0	68.0	NaN
gene_4041	46.0	NaN	212.0	25.0	NaN
gene_6566	42.0	NaN	183.0	NaN	NaN
gene_6857	41.0	NaN	75.0	56.0	125.0
gene_9176	NaN	134.0	NaN	NaN	NaN
gene_9175	NaN	121.0	NaN	NaN	NaN
gene_5388	NaN	119.0	NaN	40.0	NaN
gene_203	NaN	75.0	NaN	NaN	NaN
gene_15242	NaN	75.0	NaN	NaN	NaN
gene_11409	NaN	64.0	NaN	NaN	NaN
gene_18570	NaN	60.0	NaN	49.0	97.0
gene_4042	NaN	NaN	177.0	NaN	NaN
gene_4053	NaN	NaN	163.0	NaN	NaN
gene_17077	NaN	NaN	98.0	NaN	NaN
gene_10916	NaN	NaN	62.0	NaN	NaN
gene_3540	NaN	NaN	NaN	47.0	NaN

gene_15250	NaN	NaN	NaN	24.0	NaN
gene_9275	NaN	NaN	NaN	24.0	NaN
gene_19375	NaN	NaN	NaN	NaN	88.0
gene_1322	NaN	NaN	NaN	NaN	83.0
gene_7899	NaN	NaN	NaN	NaN	53.0
gene_5590	NaN	NaN	NaN	NaN	48.0

- O gene 230 é o único expressivamente ativo nos cinco tumores, sendo um forte indicador de precursor de células tumorais.
- **Pulmão:** O gene 289 é expressivo apenas para o pulmão, apresentando 65% de presença.
- **Próstata:** O gene 15242 é expressivo apenas para a próstata, apresentando 78% de presença.
- **Mama:** O gene 4041 é muito expressivo para a mama (72%), e o gene 4042 é muito expressivo APENAS para a mama (61%).
- **Cólon:** O gene 3540 é muito expressivo apenas para o cólon (63%).
- **Rim:** Aproximadamente 88% das amostras possuem os genes 5380 e 6857 como os mais expressivos.



- **Comparativo dos genes menos expressivos:**

	LUAD/Pulmao	PRAD/Prostata	BRCA/Mama	COAD/Colon	KIRC/Rim
gene_24	133.0	108.0	283.0	76.0	136.0
gene_14	115.0	104.0	206.0	66.0	65.0
gene_30	103.0	80.0	247.0	NaN	NaN

gene_13	92.0	104.0	189.0	73.0	97.0
gene_37	90.0	127.0	249.0	NaN	123.0
gene_25	86.0	NaN	182.0	52.0	NaN
gene_41	83.0	109.0	184.0	NaN	130.0
gene_31	72.0	NaN	157.0	NaN	74.0
gene_43	71.0	NaN	170.0	NaN	93.0
gene_10	70.0	NaN	178.0	62.0	NaN
gene_18	NaN	86.0	NaN	58.0	NaN
gene_44	NaN	67.0	NaN	NaN	NaN
gene_36	NaN	65.0	NaN	39.0	NaN
gene_21	NaN	62.0	NaN	39.0	56.0
gene_26	NaN	NaN	NaN	40.0	96.0
gene_33	NaN	NaN	NaN	36.0	77.0

- O gene 24 é o menos expressivo de todas as amostras;
- Os genes 37, 14 e 13 lideram, após o gene 24, como os menos expressivos, nessa respectiva ordem;
- **Próstata:** O gene 44 não é expressivo apenas para a próstata;




- **Rim:** O gene 26 não é expressivo apenas para o rim;
- O gene 33 não é expressivo apenas para cólon e rim.
- **Proporção dos tumores para a amostra (valores aproximados):**
 - 18% das amostras são de LUAD - Pulmão
 - 17% das amostras são de prad - próstata
 - 37% das amostras são de brca -mama
 - 10% das amostras são de coad - colon
 - 18% das amostras são de kirc - rim

3.2. Plotagens Básicas

Durante a análise também foi levantada a realização de plotagens para verificar o comportamento dos genes analisados nas amostras.

O heatmap abaixo realiza a contagem de frequência extrema por classe analisada:






Com isso podemos separar os nosso dataset em:

- Genes mais Expressos: O *gene_230* destacou-se por apresentar uma alta contagem de expressão em todas as classes tumorais, pico em câncer de mama, sendo um gene de expressão global. Por um outro lado o *gene_9176*(Próstata), *gene_4042*(Mama) e *gene_19375*(Rim) exibem contagens restritas a apenas um tipo tumoral específico
- Genes Menos Expressos: O *gene_24* e o *gene_37* concentram as maiores frequências de baixa expressão no grupo de câncer de Mama e Rim, indicando um possível silenciamento recorrente nesses tecidos.



A estimativa de densidade de probabilidade(KDE) reforça essa diferenciação:





Para a maioria dos tecidos, a distribuição dos genes mais expressos é predominantemente unimodal e concentrada no intervalo entre 50 e 150 unidades. O grupo BRCA diverge desse padrão, apresentando uma curva ampla e deslocada para a direita, com poucos em 200 unidades, o que indica uma intensidade média de transcrição maior que às demais classes. Algo similar ocorre na densidade dos genes menos expressos: enquanto a maior parte dos tecidos mantém a massa restrita a valores baixos, o tecido mamário estende sua distribuição até valores de 300 unidades, reafirmando uma maior dispersão global.

A investigação do perfil e da variabilidade individual por meio dos gráficos de boxplot permite categorizar a estabilidade desses marcadores:




Os genes globais *gene_230* e *gene_5380* apresentam medianas elevadas em torno de 16,5 e um IQR bastante reduzido, confirmando sua alta e constante abundância ao longo das amostras. Já os marcadores específicos por tumor exibem ampla variação, como observado no *gene_9176*, onde a mediana permanece próxima a 0 enquanto uma cauda longa de outliers atinge valores expressivos em amostras específicas. Por fim, os genes suprimidos confirmam a ausência de transcrição regular: *gene_24* e *gene_37* mantêm mediana e quartis zerados, registrando valores positivos apenas como outliers, enquanto *gene_14* e *gene_13* registram medianas inferiores a 0,5.

3.3. Análise Multivariada


A análise multivariada revela uma forte estrutura de coexpressão entre os genes de alta variância. Indicando a existência de redes compartilhadas. A matriz de correlação evidencia blocos bem definidos de correlação, onde pares de genes variam de forma muito similar






Paralelamente, ao estender a análise para as variáveis do tipo tumoral codificadas, observam-se associações diretas e específicas entre certos genes e classes de câncer. Tudo isso colabora para o alto potencial preditivo desses atributos para algoritmos de classificação.

A redução de dimensionalidade por meio da Análise de Componentes Principais (PCA) demonstra que uma parcela expressiva da variância total dos dados pode ser sintetizada em poucas dimensões.



As duas primeiras componentes principais (PC1 e PC2) capturam juntas 54,69% da variabilidade global (29,9% e 24,8%, respectivamente). No espaço projetado, observa-se uma separabilidade clara entre a maioria dos tipos tumorais: as amostras de PRAD e KIRC formam *clusters* completamente isolados nos extremos do plano, enquanto LUAD, BRCA e COAD apresentam agrupamentos bem estruturados, exibindo apenas zonas pontuais de sobreposição em suas fronteiras.

Por fim o Clustermap consolida relação entre os perfis e as classes tumorais através de uma visão bidimensional



A árvore hierárquica aplicada às amostras (eixo vertical) reconstrói com elevada precisão os cinco grupos biológicos, alinhando os padrões de cores aos rótulos reais dos tumores. Simultaneamente, o dendrograma dos genes (eixo horizontal) agrupa os marcadores em blocos funcionais claros de alta e baixa expressão relativas (tons vermelhos e azuis). Esse comportamento conjunto confirma que a assinatura transcriptômica de alta variância possui estrutura biológica robusta o suficiente para discriminar com eficiência os diferentes tipos de câncer.

3.4. Conclusão da Análise Exploratória

A Análise Exploratória de Dados revelou que a matriz transcriptômica possui uma estrutura biológica altamente informativa e discriminativa. A investigação univariada e bivariada permitiu categorizar os genes em dois perfis funcionais claros: genes de expressão constitutiva/global (como o *gene_230*), que apresentam abundância basal elevada e homogênea em todas as amostras, e genes marcadores especificamente regulados, que exibem variação condicional estritamente dependente do tipo tecidual (como o *gene_9176* para PRAD e o *gene_4042* para BRCA). Além disso, a presença de genes fortemente silenciados (com mediana e dispersão nulas) valida a eficácia dos filtros preliminares de baixa variância para eliminação de ruído.

Sob a perspectiva multivariada, a identificação de blocos de expressão linear indica que a informação contida nas dezenas de milhares de atributos pode ser sintetizada em um espaço de menor dimensão sem perda crítica de variabilidade explicativa. Esse comportamento foi ratificado pela Análise de Componentes Principais (PCA), na qual apenas duas dimensões capturaram 54,69% da variância total, projetando os tecidos PRAD e KIRC em regiões ortogonais e bem isoladas, e mantendo LUAD, BRCA e COAD em agrupamentos densos e coesos. A coerência entre a reconstrução do dendrograma no Clustermmap e a rotulagem real das amostras confirma que a assinatura de expressão preserva a separabilidade topológica dos tumores.



4. Treinamento do Modelo de ML

4.1. Divisão do Dataset – Treino e Teste

A realização da divisão do dataset ocorreu de forma padrão, dividindo os dados em 2 datasets diferentes ou 4 considerando a divisão em treino e teste:

- X – Presença dos genes como variáveis preditoras, mantendo o uso dos genes mais relevantes previamente selecionados e escolhidos
- Y – Em Y a variável target, os tipos de tumor, foram utilizados para ser a variável a ser prevista, como já discutido anteriormente.

A divisão entre treino e teste seguiu os parâmetros convencionais onde um quinto dos dados foi usado para teste e o restante para o treinamento eficaz do modelo de machine learning.

4.2 Padronização/Normalização das variáveis numéricas

A padronização foi feita utilizando um método chamado de Robust Scaler, que pega os valores dos genes e os padroniza utilizando a mediana e o IQR (Distância interquartil), assim sendo robusta a valores que são outliers, evitando o enviesamento dos dados e mantendo as proporções do dataset original.



4.3 Tratamento com Label Encoding

Como visto previamente, a variável que representa o tipo de tumor é a única variável não numérica, portanto seria necessário o tratamento desse tipo de variável com Label Encoding.

Os dados reservados em Y sofreram label encoding e fatalmente convertidos em valores numéricos resultando em:

- BRCA -> 0
- COAD -> 1
- KIRC -> 2
- LUAD -> 3
- PRAD -> 4

4.4 Seleção de Features

A seleção de features foi dividida em duas partes:

1. Utilização de MDI (Mean Decrease in Impurity), método que avalia a importância de cada variável na construção de um modelo, baseando-se em índices como Gini ou Entropia, em cada ramo das árvores.

Este processo se deu através de um teste de uma árvore de decisão (Random Forest Classifier) baseada no dataset completo, assim obtendo o impacto que cada gene teve na sua construção e as métricas necessárias para analisar o peso de cada variável no modelo,



após este processo foram selecionados apenas os genes que apresentavam importância maior que 0,1%.

Esta porcentagem foi tida como a mais eficaz e a que melhor reduz o ruído, sem impactar os genes que poderiam ser importantes para o modelo.

2. Para a segunda etapa foi utilizado o método SHAP, que testa todas as combinações de variáveis e assim mede o peso que cada uma teve no modelo final, assim permitindo obter as mais importantes.

Portanto, para essa parte também foi utilizado Random Forest Classifier, e depois aplicado o método acima. Ao final obtivemos em ordem decrescente uma lista com os pesos, assim selecionamos uma quantidade de 50 genes. Porém no modelo final notamos que essa quantidade poderia ser reduzida, testamos o modelo com números diferentes de genes, ao final chegamos a conclusão de que apenas 14 genes são extremamente relevantes para que o modelo tenha uma ótima precisão.

4.5 Treinamento do Modelo

Para a etapa de modelagem definitiva, foi utilizado o algoritmo Random Forest Classifier, configurado com um conjunto de 500 árvores de decisão. A semente aleatória foi fixada para garantir a reprodutibilidade dos resultados, e o processamento foi paralelizado para otimizar o tempo de execução. O modelo foi treinado utilizando 50 variáveis selecionadas e previamente padronizadas, juntamente com o valor de rótulos de treino. Após a fase de ajuste, foram geradas as previsões para o conjunto de teste, cujos resultados servirão de base para a avaliação final de métricas de desempenho.



5. Métricas e Avaliações

5.1. Acurácia e Métricas Iniciais

O classification report foi gerado utilizando métricas como:


- Precisão – Indica quantas predições positivas encontradas pelo modelo realmente eram positivas;
- Recall – De todos os positivos presentes na amostra, quantos o modelo conseguiu encontrar;
- F1-Score – Indica o desempenho do modelo, levando em consideração o equilíbrio entre precisão e recall.

Os resultados iniciais revelaram uma acurácia de 100%, inicialmente esses resultados podem parecer extremamente positivos, porém podem revelar problemas como vazamento de dados e/ou overfitting, visto essa problemática, foi necessário realizar novos testes com variáveis diferentes e dados externos aos dados de treino e teste.

5.2. Matriz de Confusão

A matriz de Confusão analisa os dados previstos em comparação com o valor real, abaixo é apresentada a matriz obtida:





O processo de redução de dimensionalidade por Random Forest e SHAP identificou com precisão os 50 genes com maior poder de separação entre os tipos de tumores e obteve 100% de acurácia.



5.3. Correções e Testes

Devido a alta acurácia do modelo é preciso realizar alguns testes para observar se não existe nenhum problema com os dados que o modelo foi treinado e avaliou após o treinamento

5.3.1 Overfitting

Para descartar a teoria de overfitting os dados foram submetidos a validação cruzada K-Fold, que tem o intuito de ver o quão bem o modelo generaliza novos dados. O dataset foi submetido a uma análise com 5 folds obtendo as seguintes métricas para cada fold


	Fold	Acurácia
0	Fold 1	98,76%
1	Fold 2	100.00%
2	Fold 3	100.00%
3	Fold 4	99.38%
4	Fold 5	100.00%
Média Geral	–	99.63%

Após essa análise podemos descartar a hipótese de overfitting, visto que a variação da porcentagem entre os folds é ínfima



5.3.2 Vazamento de Dados

O vazamento de dados ocorre quando durante a etapa de treinamento, alguns dados de teste acabam vazando para o modelo, dessa forma o modelo acaba por decorar os dados e dessa maneira sabendo prever seus resultados. Para analisar se a situação da acurácia elevada era resultante de um data leakage decidimos imprimir uma das árvores de decisão da random forest



No nó da árvore podemos observar que 407 amostras são analisadas pelo modelo, o que vai de acordo com a divisão previamente estabelecida de 80% e 20%. Dessa forma podemos descartar totalmente a hipótese de vazamento dos dados no modelo de machine learning.

5.3.3. Testes avulsos

Por último, apenas por fim de confirmação da eficiência do modelo, exportamos o modelo e testamos ele com dez amostras diferentes nunca antes vistas pelo notebook de limpeza, tratamento e modelagem. O acerto do modelo nesses casos seria a prova que nenhum problema grave aconteceu na estruturação do trabalho e ele estaria pronto para ser usado.

Após os testes, o modelo obteve 100% de acerto nos dez testes a que foi submetido, descartando qualquer hipótese de overfitting ou vazamento de dados.

6. Conclusões

A partir de uma análise de todos os aspectos e nuances deste trabalho, podemos concluir que apesar do grande volume de genes, cada tumor possui um perfil genético distinto, o que permite com que poucos genes consigam descrever, com precisão, o dataset como um todo. E apesar da colinearidade dos dados e suas relações específicas, o que faz com que o dataset se torne multivariado, uma vez que a interação gênica é um fator relevante, é possível notar que como cada tumor apresenta perfis genéticos distintos o modelo consegue identificar padrões e genes muito relevantes para cada tipo de câncer.

Dado isso, para selecionar os melhores genes para o modelo, utilizamos de métodos estatísticos (MDI e SHAP) para a seleção das features mais importantes. Após o treinamento conseguimos alcançar 100% de precisão na previsão dos cânceres, como este resultado apesar de ser positivo e comprovativo às conclusões acerca do dataset, foi necessário verificar a



factualidade desses resultados, evitando *data leakage* e *overfitting*, e mesmo depois dessas verificações o resultado se manteve aproximadamente igual.

